Arquitectura Tècnica

XC Gradient — Visió General del Sistema

Abril 2026 · Confidencial

1. Visió d'Alt Nivell

El sistema XC Gradient transforma documentació industrial no estructurada en respostes accionables mitjançant un pipeline d'IA completament privat. Cap dada del client abandona les seves instal·lacions.

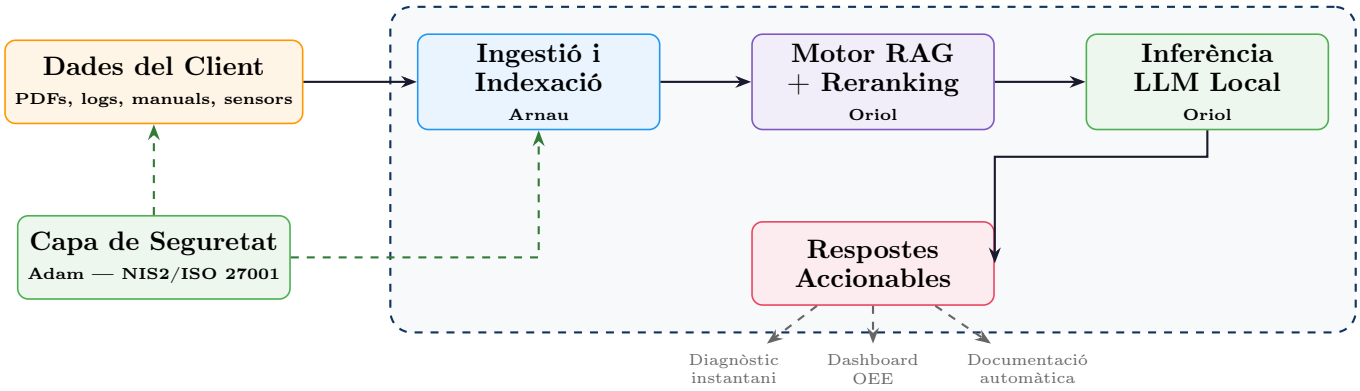

Principi fonamental: cada client disposa d'un contenidor privat aïllat. La inferència del model de llenguatge s'executa localment dins les instal·lacions del client. Zero dependència de proveïdors d'IA externs (OpenAI, Azure, Google).

2. Arquitectura Detallada per Capa

2.1 Capa d'Ingestió i Indexació (Propietari: Arnau Noguer, CTO)

Processa tota la documentació del client i la converteix en un índex consultable:

- **Pipeline d'ingestió:** PDFs, fitxers Word, logs de manteniment, dades de sensors i registres d'incidents es processen, segmenten i indexen.
- **Recuperació híbrida:** combinació de cerca densa (embeddings vectorials) i dispersa (BM25) sobre el vector store privat del client.
- **Construcció d'ontologia:** mapa conceptual del domini manufacturerer del client — tipus de màquina, modes de fallada, famílies de paràmetres. Aquesta ontologia es refina amb cada desplegament i crea costos de canvi creixents.
- **Vector store aïllat:** un índex per client, mai compartit entre comptes.

2.2 Capa de Post-Recuperació (Propietari: Oriol Farrés, CEO — IP de Tesi)

Optimitza la selecció del context que rep el model de llenguatge. Aquí resideix la IP core:

El pas de recuperació retorna n chunks candidats. El reranker selecciona la finestra de context òptima.
Cadena de Markov absorbent: el pipeline RAG es formalitza com una cadena de Markov sobre conjunts de documents candidats, on cada transició representa una operació de reranking.
Integral de Choquet: les transicions de reranking s'avaluen mitjançant un framework de teoria de jocs (integral de Choquet sobre un DAG proposicional) que captura *sinergies i redundàncies* entre chunks — una capacitat que els mètodes de scoring additius no poden oferir.
Restricció de latència: <50ms en CPU per reranking, compatible amb desplegament on-premises sense cluster GPU.

2.3 Capa d'Inferència del Model (Propietari: Oriol Farrés, CEO — IP de Tesi)

El model de llenguatge genera la resposta final a partir del context optimitzat:

- **S-QDoRA (Sparse Quantized DoRA):** mètode de fine-tuning multi-tenant que dóna a cada client un adaptador dispers lleuger sobre un model base quantitzat compartit. Permet especialització per client sense emmagatzemar un model complet per client.
- **Speculative decoding:** un model petit "draft" genera tokens candidats que el model objectiu verifica en paral·lel, aconseguint reducció de latència de 2–4× — crític per a desplegaments sense accés a clusters GPU.
- **Inferència local:** dual RTX 3090 (48GB VRAM total) permet executar models quantitzats de 70B paràmetres.

2.4 Capa de Seguretat i Topologia (Propietari: Adam Sarrate, COO/CISO)

- **Topologia de xarxa:** defineix com la capa XC Gradient s'integra dins la infraestructura existent del client — què es connecta a què, on viu el contenidor privat, com els operaris accedeixen al node d'inferència.
- **Aïllament entre clients:** garanties d'aïllament estricte, control d'accés al contenidor privat, i model de flux de dades que assegura que cap dada arriba a proveïdors externs.
- **Conformitat:** arquitectura dissenyada per complir NIS2 (UE 2022/2555) i ISO 27001 de sèrie.

3. Framework d'Avaluació

Per garantir la qualitat de les respostes, XC Gradient utilitza un framework de benchmarking propi que supera les limitacions de RAGAS:

Component	Descripció
BERTScore (DeBERTa)	Similitud semàntica entre resposta generada i referència
NLI asimètric	Verificació d'entailment i contradicció
Cross-encoder	Rellevància entre consulta i resposta
Jutge LLM (70B)	Avaluació estructurada en una sola crida
Mètode	Ensemble lineal de 7 features, ajustat contra 200 exemples anotats per humans
Objectiu	A-score >0.80 al PoC de Decfa (Arnau, target: 15 maig 2026)
Protocol estadístic	Wilcoxon signed-rank amb correcció de Bonferroni, pre-registrat

4. Diferenciació Tècnica vs. Estat de l'Art

Capacitat	RAG Estàndard	XC Gradient
Reranking	Scoring additiu (lineal)	Choquet integral (captura sinergies)
Multi-tenancy	Un model per client (costós)	S-QDoRA: adaptadors dispersos compartint base
Latència	Estàndard	Speculative decoding (2–4× reducció)
Privacitat	Cloud-dependent	100% on-premises, zero exfiltració
Domini	Genèric	Ontologies industrials per client
Avaluació	RAGAS (limitat)	Ensemble 7-features calibrat amb humans

5. Stack Tecnològic

Capa	Tecnologies
Inferència	Models quantitzats 70B, dual RTX 3090, speculative decoding
Retrieval	Vector store aïllat per client, cerca híbrida densa+dispersa
Reranking	Pipeline Markov+Choquet (C++/Python, <50ms CPU)
Fine-tuning	S-QDoRA amb hot-swap d'adaptadors LoRA
Backend	Python, FastAPI
Frontend	React, dashboard OEE 2D interactiu
Seguretat	Contenidors aïllats, NIS2/ISO 27001 compliant
DevOps	Kubuntu 24.04, Tailscale per accés remot